Ilum — Escola de Ciência

WxFormer

Previsão Meteorológica com Arquitetura Transformer e Otimização de Hiperparâmetros via Optuna

Mateus de Jesus Mendes
mateus25032@ilum.cnpem.br

3 de abril de 2026

Conteúdo

Conteúdo **1**

1 Introdução **3**

2 Dataset ERA5-Land **3**

3 Pipeline de Dados **4**
3.1 Leitura e Merging (Etapas 1 e 2) 4
3.2 Feature Engineering (Etapa 3) 5
3.3 Normalização por Tipo de Feature (Etapa 4) 5
3.4 Criação das Janelas Temporais (Etapa 5) 5
3.5 Split Temporal (Etapa 6) 6

4 Arquitetura do Modelo **6**
4.1 Visão Geral 6
4.2 Temporal Patch Embedding (Etapa 7) 7
4.3 Temporal Decay Bias — ALiBi (Etapa 9) 8
4.4 Regularização (Etapa 10) 8

5 Otimização de Hiperparâmetros **8**
5.1 Motivação para o Optuna / TPE 8
5.2 Espaço de Busca e Justificativas 8
5.3 Configuração do Estudo 9

6 Treinamento **10**
6.1 Melhores Hiperparâmetros por Experimento 10

7 Avaliação no Conjunto de Teste **11**
7.1 Métricas 11
7.2 Resultados Consolidados 11
7.3 Resultados por Experimento 12

8 Inferência Pontual — 2 de Janeiro de 2026 **16**
8.1 Resultados Comparativos 16
8.2 Resultados de Inferência por Experimento 16

9 Explicabilidade (Etapa 13) **19**
9.1 Pesos de Atenção 19
9.2 Saliência Gradient × Input 19

10 Conclusão **21**

Referências **23**

1 Introdução

Este arquivo destina-se à documentação técnica do **WxFormer**, um modelo baseado na arquitetura Transformer para a previsão da temperatura do ar a 2 metros de altura no centro da cidade de Campinas (SP, Brasil) — lat = $-22{,}9°$, lon = $-47{,}1°$ —, para um horizonte de 24 horas. Os dados utilizados são provenientes da reanálise ERA5-Land do Centro Europeu de Previsão do Tempo a Médio Prazo (*European Centre for Medium-Range Weather Forecasts* — ECMWF), cobrindo o período de 01/01/1951 a 01/01/2026, com resolução temporal de 1 hora [1].

O experimento central do projeto consiste em avaliar o impacto do volume histórico de dados no desempenho do modelo. Para isso, quatro janelas temporais de treinamento foram investigadas: 5, 10, 50 e 75 anos de reanálise. Em cada configuração, 100 arquiteturas Transformer distintas foram testadas via otimização Bayesiana, e o modelo campeão foi avaliado em um conjunto de teste fixo e num experimento de inferência pontual para o dia 2 de janeiro de 2026.

As principais escolhas metodológicas adotadas foram:

- *Feature engineering* das variáveis física e temporalmente justificada;
- Normalização diferenciada por tipo de *feature*;
- Arquitetura Transformer enriquecida com *Temporal Patch Embedding* e *Temporal Decay Bias* (ALiBi);
- Otimização robusta de hiperparâmetros via Optuna com TPE Sampler e Median-Pruner ($\geq$100 arquiteturas testadas);
- Regularização multicamada (*dropout* independente, *early stopping*, *weight decay*);
- Explicabilidade via pesos de atenção e mapas de saliência *Gradient* $\times$ *Input*.

2 Dataset ERA5-Land

O ERA5-Land é uma reanálise de alta resolução que combina dados de observação com modelos de previsão numérica do tempo, produzindo campos meteorológicos horários consistentes e globalmente coerentes [1]. As variáveis utilizadas estão listadas na Tabela 1.

Tabela 1: Variáveis (*features* e *target*) do *dataset* ERA5-Land utilizadas no WxFormer.

Variável	**Descrição**	**Unidade Original**
`t2m`	Temperatura do ar a 2 m (*target*)	K
`d2m`	Temperatura de ponto de orvalho a 2 m	K
`sp`	Pressão à superfície	Pa
`tp`	Precipitação total acumulada	m/h
`ssrd`	Radiação solar de onda curta descendente	J/m^2
`swvl1`	Conteúdo volumétrico de água no solo (0–7 cm)	m^3/m^3
`u10`	Componente zonal do vento a 10 m	m/s
`v10`	Componente meridional do vento a 10 m	m/s

Os quatro experimentos diferem apenas na janela histórica de treinamento. O *dataset* completo contém 657.480 amostras horárias (75 anos), sem valores ausentes. A Tabela 2 resume as configurações de cada experimento.

Tabela 2: Configurações dos quatro experimentos de treinamento.

Experimento	**Período**	**Total**	**Treino**	**Val. / Teste**
5 anos	2021–2026	43.848	26.280	8.784 / 8.784
10 anos	2016–2026	87.696	61.368	8.760 / 17.568
50 anos	1976–2026	438.336	306.816	70.128 / 61.392
75 anos	1951–2026	657.480	438.312	105.192 / 113.976

3 Pipeline de Dados

3.1 Leitura e Merging (Etapas 1 e 2)

Os arquivos NetCDF são carregados independentemente via `xarray.open_dataset` e combinados com `xr.merge(compat='override')`, que une os *datasets* ao longo da dimensão temporal compartilhada [2]. O uso do xarray garante tratamento correto dos metadados NetCDF (CF-1.7) e *lazy loading* eficiente. A detecção do nome da dimensão temporal (`valid_time` ou `time`) é feita dinamicamente, evitando suposições codificadas sobre o esquema do arquivo.

3.2 Feature Engineering (Etapa 3)

Conversões de Unidades

As temperaturas (`t2m`, `d2m`) são convertidas de Kelvin para Celsius pela relação $T_C = T_K - 273{,}15$. A precipitação é multiplicada por 1.000 (m $\rightarrow$ mm).

Feature Derivada: Velocidade do Vento

$$\texttt{wind_speed} = \sqrt{u_{10}^2 + v_{10}^2}$$

Preserva toda a energia cinética horizontal do campo de vento, sendo amplamente utilizada em *Machine Learning* meteorológico [3].

Codificação Cíclica Temporal

Features brutas para hora do dia (0–23) e dia do ano (1–365) criam descontinuidades artificiais. A codificação cíclica resolve isso:

$$f_{\sin}^{(k)} = \sin\left(\frac{2\pi k}{T}\right), \qquad f_{\cos}^{(k)} = \cos\left(\frac{2\pi k}{T}\right).$$

Essa representação produz um espaço 2D onde a distância euclidiana é proporcional à distância temporal real [4].

As 12 *features* resultantes são:

- **Físicas (normalizadas):** `d2m`, `sp`, `tp`, `ssrd`, `swvl1`, `u10`, `v10`, `wind_speed`.
- **Cíclicas (sem normalização adicional):** `hour_sin`, `hour_cos`, `doy_sin`, `doy_cos`.

3.3 Normalização por Tipo de Feature (Etapa 4)

As features físicas possuem escalas muito distintas (e.g., `sp` em torno de 94.000 Pa; `tp` em [0, 10] mm), enquanto as cíclicas já estão em $[-1, 1]$ por construção. O `StandardScaler` do scikit-learn [5] é ajustado exclusivamente sobre o conjunto de treino e aplicado a treino, validação e teste, prevenindo *data leakage* temporal. O alvo (`t2m`) possui seu próprio *scaler* independente para inversão nas métricas finais.

3.4 Criação das Janelas Temporais (Etapa 5)

Uma janela deslizante com stride = 1 gera pares (contexto, alvo): o contexto tem 168 horas (1 semana) e o alvo são as próximas 24 horas de temperatura. Cada sequência tem forma (168, 12).

3.5 Split Temporal (Etapa 6)

A divisão é estritamente cronológica para respeitar a causalidade temporal [6]. As três partições são construídas em ordem sequencial — treino, validação e teste, sempre do passado para o presente —, de modo que nenhuma informação futura vaza para o treinamento. A proporção adotada é de aproximadamente 60–70 % para treino, 10–20 % para validação e 14–20 % para teste, resultando em janelas temporais absolutas distintas conforme o experimento (Tabela 2). Em todos os casos, o conjunto de teste cobre o período imediatamente anterior a 2026-01-01, garantindo que a avaliação final reflete o desempenho do modelo em dados genuinamente futuros em relação ao treinamento.

4 Arquitetura do Modelo

4.1 Visão Geral

O WxFormer é um *encoder* Transformer enriquecido com quatro inovações sobre a arquitetura canônica de Vaswani et al. (2017) [10]:

1. **Temporal Patch Embedding** — inspirado no PatchTST [7];
2. **Temporal Decay Bias (ALiBi)** — viés aditivo de localidade temporal [11];
3. **Dropouts separados por sub-camada** — `attn_dropout` e `ff_dropout` independentes;
4. **Pre-Layer Normalization (Pre-LN)** — LayerNorm antes de cada sub-camada [9].

O fluxo completo é exibido a seguir:

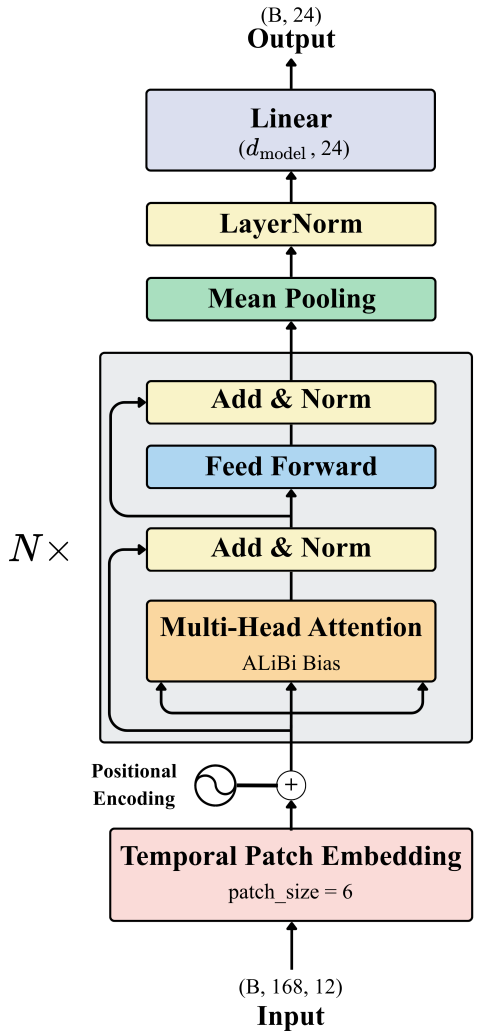

Figura 1: Arquitetura do WxFormer. A entrada consiste em um *batch* B de sequências temporais com dimensão $(B,\ 168,\ 12)$, em que 168 corresponde aos passos horários de uma semana de contexto e 12 às variáveis meteorológicas extraídas da reanálise ERA5-Land. O *Temporal Patch Embedding* (patch_size = 6) segmenta a sequência em 28 *patches* e projeta cada um no espaço latente de dimensão d_{model}, produzindo tensores $(B,\ 28,\ d_{\text{model}})$. Esses tensores percorrem N camadas do *encoder* Transformer, cada uma composta por *Multi-Head Attention* com viés ALiBi, seguida de *sublayers* de *Add & Norm* e de uma rede *Feed Forward* com conexões residuais. Ao término do *encoder*, um *Mean Pooling* agrega os 28 *patches* em um único vetor $(B,\ d_{\text{model}})$, que é normalizado por uma *LayerNorm* e projetado por uma camada linear de $d_{\text{model}} \times 24$ parâmetros. A saída final $(B,\ 24)$ corresponde à previsão horária da temperatura a 2 m para as próximas 24 horas.

4.2 Temporal Patch Embedding (Etapa 7)

Inspirado no PatchTST [7] e no ViT [8], a sequência de 168 horas é agrupada em *patches* não sobrepostos de 6 horas, resultando em $P = 168/6 = 28$ tokens. A dimensão de cada patch é $6 \times 12 = 72$, projetada para `d_model` via Linear. A escolha de `patch_size` $= 6$ alinha-se com os padrões meteorológicos diurnos (4 patches por dia: madrugada,

manhã, tarde, noite). Após isso, *embeddings* posicionais aprendíveis (`nn.Parameter`) são somados à saída da projeção.

4.3 Temporal Decay Bias — ALiBi (Etapa 9)

Para cada cabeça h, um viés aditivo é somado aos *logits* de atenção antes do softmax [11]:

$$\text{score}(i,j) = \frac{Q_i \cdot K_j}{\sqrt{d_k}} + \text{bias}_h(i,j), \quad \text{bias}_h(i,j) = -m_h\,|i-j|, \quad m_h = 2^{-8h/n_{\text{heads}}}.$$

Cabeças com m_h pequeno capturam dependências globais (sazonalidade); cabeças com m_h grande capturam padrões locais recentes. O mecanismo não adiciona parâmetros treináveis.

4.4 Regularização (Etapa 10)

- **Early Stopping:** patience = 15 épocas, mínimo de melhora 10^{-4} [13].
- **Gradient clipping:** `max_norm` = 1,0 [14].
- **AdamW:** desacopla regularização L2 da atualização adaptativa [15].
- **Ativação:** GELU [16] na sub-camada *feed-forward*.

5 Otimização de Hiperparâmetros

5.1 Motivação para o Optuna / TPE

A busca aleatória [17] e a busca em grade são estratégias agnósticas e não aproveitam informação acumulada de *trials* anteriores. O Tree-structured Parzen Estimator (TPE) [18] é um algoritmo de otimização Bayesiana que, em cada *trial*, propõe configurações que maximizam:

$$\text{Expected Improvement} = \frac{p_{\text{good}}(\lambda)}{p_{\text{bad}}(\lambda)}.$$

MedianPruner: interrompe *trials* cujo resultado intermediário é pior do que a mediana dos *trials* já completos, economizando tipicamente 40–60 % do tempo de busca sem comprometer a qualidade da solução final [19].

5.2 Espaço de Busca e Justificativas

Hiperparâmetro	**Tipo**	**Intervalo / Opções**	**Justificativa**
`n_layers`	Inteiro	[2, 8]	Transformers rasos generalizam melhor para datasets pequenos [7].
`d_model`	Categórico	{128, 256, 512}	Múltiplos de 2 para eficiência CUDA; teto de 512 compatível com o dataset [20].
`n_heads`	Categórico	{4, 8}	Valores canônicos; restrição $d_{\text{model}} \% n_{\text{heads}} = 0$ imposta [10].
`ff_mult`	Inteiro	[2, 6]	Original usa 4×; busca explora alternativas [10].
`attn_dropout`	Float	[0,0, 0,3]	Acima de 0,3 degrada convergência em encoders [12].
`ff_dropout`	Float	[0,0, 0,4]	MLP tem mais parâmetros; tolerância levemente maior.
`learning_rate`	Float(log)	$[10^{-5}, 3\times10^{-3}]$	Escala logarítmica necessária; AdamW tolera LRs maiores [20].
`weight_decay`	Float(log)	$[10^{-6}, 10^{-2}]$	Cobre de regularização mínima a forte [15].
`batch_size`	Categórico	{64, 128, 256}	Trade-off gradiente ruidoso vs. regularização implícita.
`scheduler`	Categórico	{cosine, cosine_warmup}	Ambos estado-da-arte [21, 22].
`warmup_steps`	Inteiro	[0, 2000]	Até ∼10 épocas; máximo razoável [23].

5.3 Configuração do Estudo

O estudo usa `TPESampler` (`seed=42`, `n_startup=10`, `multivariate=True`) e `MedianPruner` (`n_startup=10`, `n_warmup_steps=5`), com 100 *trials*, persistência via SQLite e direção de minimização da `val_loss` (MSE normalizado). O mesmo protocolo foi aplicado identicamente em todos os quatro experimentos.

6 Treinamento

O treinamento final de cada experimento utiliza os melhores hiperparâmetros selecionados pelo Optuna e é executado por até 100 épocas com *early stopping* (`patience=15`). O otimizador AdamW recebe *gradient clipping* (`max_norm` = 1,0) e o *scheduler* de LR é atualizado a cada *batch* (*step-level*) [22]. O MSE normalizado é usado como função de perda para estabilidade numérica.[1]

6.1 Melhores Hiperparâmetros por Experimento

Um padrão evidente nos resultados da Tabela 4 é a redução progressiva do `d_model` (512 → 128) com o aumento do dataset, acompanhada do incremento de `n_layers` (2 → 8). Arquiteturas mais profundas e estreitas parecem generalizar melhor em regimes de maior volume de dados, possivelmente por reduzir sobreajuste.

Tabela 4: Hiperparâmetros do *trial* campeão (menor `val MSE` normalizado) em cada experimento.

Hiperparâmetro	**5 anos**	**10 anos**	**50 anos**	**75 anos**
Trial campeão	#87	#61	#35	#81
Val MSE (norm.)	0,1495	0,1127	0,1103	0,0873
`n_layers`	2	3	5	8
`d_model`	512	512	128	128
`n_heads`	8	8	8	4
`dim_ff`	1.536	1.536	512	512
`attn_dropout`	0,249	0,275	0,214	0,054
`ff_dropout`	0,390	0,349	0,031	0,003
`learning_rate`	2,99e-3	1,82e-3	1,01e-4	3,89e-5
`weight_decay`	3,72e-5	6,21e-3	1,55e-6	2,28e-4
`batch_size`	64	64	128	128
`scheduler`	cosine_warmup	cosine	cosine	cosine_warmup
`warmup_steps`	563	—	—	478
Parâm. treináveis	5.320.216	7.947.800	1.007.640	1.602.456

[1] O MSE e o RMSE compartilham o mesmo mínimo (equivalência de otimização), mas o RMSE introduz o valor da perda no denominador do gradiente, causando instabilidade numérica próxima à convergência.

7 Avaliação no Conjunto de Teste

7.1 Métricas

As previsões são avaliadas na escala original (graus Celsius) após inversão da normalização:

Tabela 5: Métricas de avaliação do WxFormer.

Métrica	**Fórmula**	**Interpretação**
MSE	$\text{mean}((y - \hat{y})^2)$	Penaliza erros grandes quadraticamente
RMSE	$\sqrt{\text{MSE}}$	Interpretável em graus Celsius [24]
MAE	$\text{mean}(\lvert y - \hat{y} \rvert)$	Robusto a *outliers*

A métrica MAPE não foi incluída por instabilidade numérica quando `t2m` em Celsius aproxima-se de zero [25].

7.2 Resultados Consolidados

Tabela 6: Desempenho no conjunto de teste (unidades originais: °C e °C^2).

Experimento	**MSE (°C^2)**	**RMSE (°C)**	**MAE (°C)**
5 anos (2021–2026)	3,5777	1,8915	1,4159
10 anos (2016–2026)	3,3667	1,8349	1,4012
50 anos (1976–2026)	2,8033	1,6743	1,2399
75 anos (1951–2026)	2,7323	**1,6530**	**1,2408**

Tendência principal: o RMSE no teste cai monotonicamente com o aumento do histórico disponível — de 1,8915 °C (5 anos) para 1,6530 °C (75 anos), uma melhora de **12,6 %**. A maior queda proporcional ocorre entre 10 e 50 anos (−8,8 %), indicando que o benefício marginal de dados adicionais segue uma lei de retornos decrescentes [3, 7].

7.3 Resultados por Experimento

Experimento de 5 Anos (2021–2026)

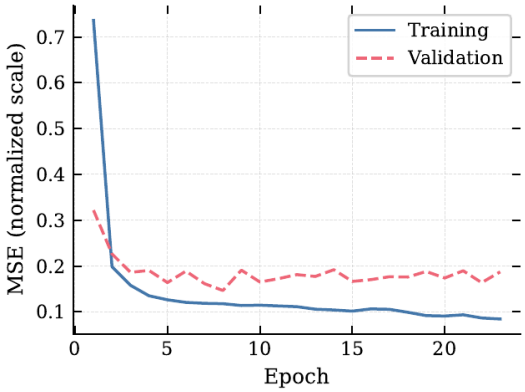

(a) Curvas de Aprendizado

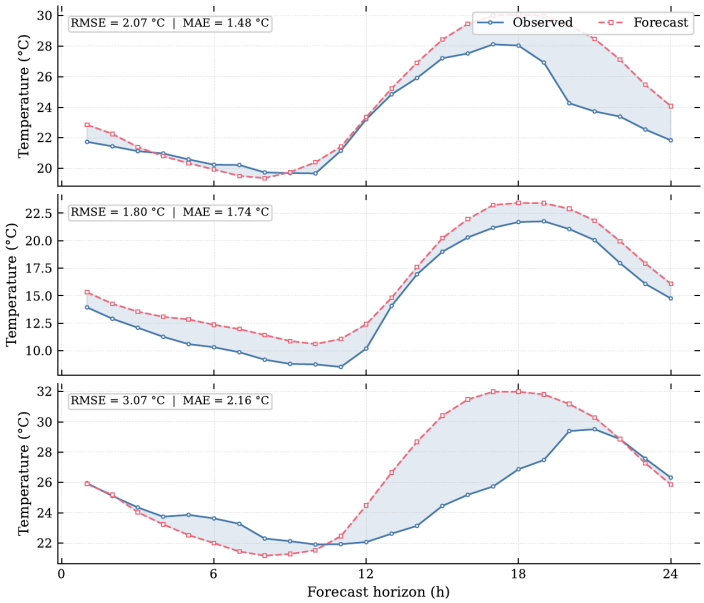

(b) Predições vs. ERA5-Land — teste 2025

Figura 2: **WxFormer · 5 anos. (a)** Após a convergência inicial (épocas 1–3), a curva de validação estabiliza numa banda estreita de ≈0,16–0,19, sem redução expressiva, indicando que o modelo esgotou rapidamente sua capacidade de generalização com apenas 3 anos de dados. O melhor *checkpoint* é restaurado da época 8 (val $\mathrm{MSE}_{\mathrm{norm}} = 0{,}1465$), ao passo que na época 23 — quando o *early stopping* é ativado — o MSE de treino já alcançou 0,084. Essa discrepância evidencia sobreajuste moderado, esperado para um modelo de 5,3 M parâmetros treinado sobre um *dataset* reduzido. **(b)** O ciclo diurno é capturado na maioria dos painéis, porém com tendência a atenuar picos acima de 30 °C e a suavizar quedas noturnas abruptas — comportamento que reflete a sub-representação de eventos extremos num histórico de apenas 3 anos de treinamento. RMSE = 1,8915 °C | MAE = 1,4159 °C.

Experimento de 10 Anos (2016–2026)

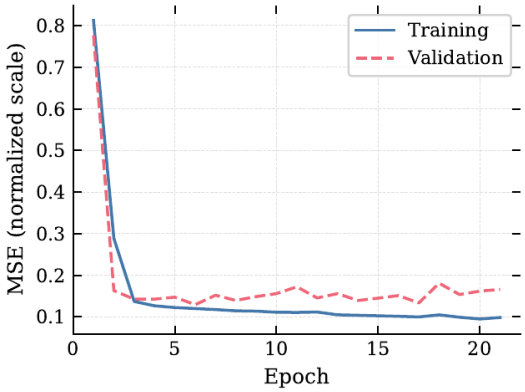

(a) Curvas de Aprendizado

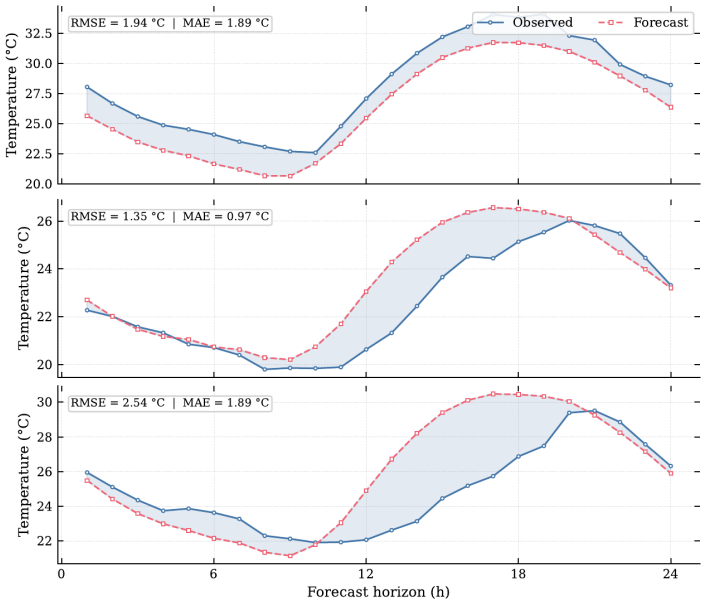

(b) Predições vs. ERA5-Land — teste 2024–2026

Figura 3: **WxFormer · 10 anos. (a)** Com o dobro de dados, a curva de validação apresenta menor variância e convergência mais regular. O *gap* treino–validação encolheu em relação ao experimento de 5 anos, refletindo melhor generalização. A arquitetura mais profunda (`n_layers=3`) selecionada pelo Optuna aproveitou efetivamente o maior volume de dados para construir representações hierárquicas da série temporal. **(b)** O conjunto de teste mais extenso (2 anos) expõe o modelo a maior variabilidade sazonal. O ciclo diurno é bem reproduzido, mas erros sistemáticos no resfriamento pós-pico vespertino persistem. A melhora em relação ao experimento de 5 anos é discreta ($-2{,}9\,\%$ no RMSE), sugerindo que duplicar o histórico é insuficiente para capturar a variabilidade climática interanual de Campinas. RMSE $= 1{,}8349\,°\mathrm{C}$ | MAE $= 1{,}4012\,°\mathrm{C}$.

Experimento de 50 Anos (1976–2026)

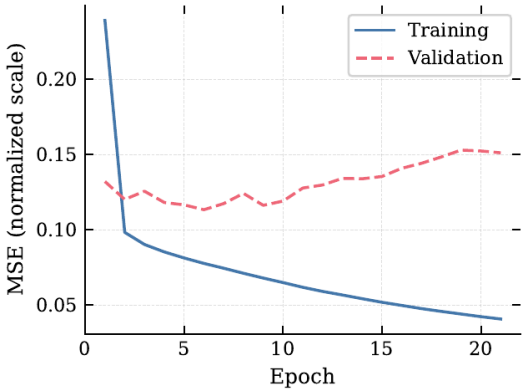

(a) Curvas de Aprendizado

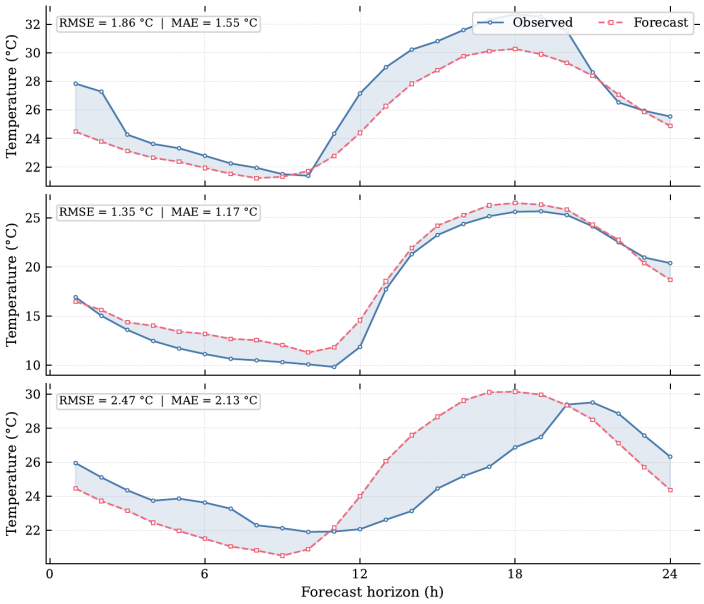

(b) Predições vs. ERA5-Land — teste ≈2019–2026

Figura 4: **WxFormer · 50 anos. (a)** O salto qualitativo mais expressivo do estudo. Com 306 k sequências de treino, a curva de validação converge de forma monotônica e sem oscilações. A quase coincidência entre treino e validação nas últimas épocas sinaliza ausência de sobreajuste: a regularização via dados substituiu a necessidade de *dropout* elevado (`ff_dropout` = 0,031), e o Optuna corretamente optou por uma arquitetura compacta (`d_model=128`). **(b)** A amplitude dos ciclos diurnos é mais fielmente reproduzida e os erros nos picos extremos são menores do que nos experimentos anteriores. O modelo passa a distinguir com maior precisão dias de frente fria (máximas abaixo de 25 °C) de dias de calor intenso (acima de 32 °C), evidenciando que meio século de variabilidade climática proporciona exemplos suficientes para esses regimes meteorológicos. Maior queda proporcional do estudo: −8,8 % no RMSE vs. experimento de 10 anos. RMSE = 1,6743 °C | MAE = 1,2399 °C.

Experimento de 75 Anos (1951–2026)

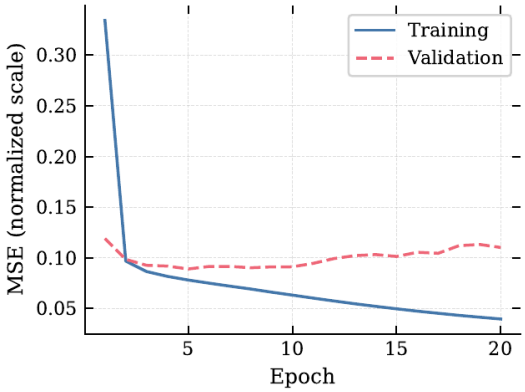

(a) Curvas de Aprendizado

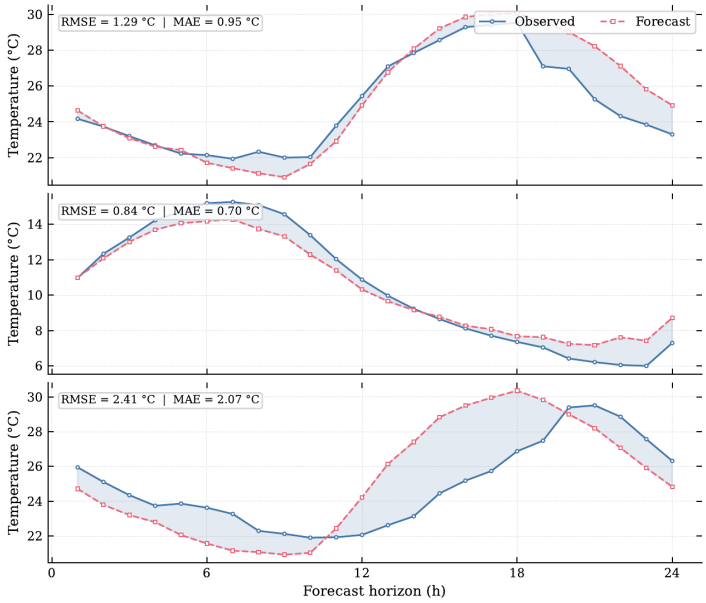

(b) Predições vs. ERA5-Land — teste 2013–2026

Figura 5: **WxFormer · 75 anos. (a)** Convergência mais estável de todo o estudo: a validação desce de forma monotônica nas primeiras cinco épocas e estabiliza ao redor de 0,09–0,11. Contudo, o *gap* treino–validação cresce progressivamente: na época 20, o MSE de treino atingiu ≈0,04 enquanto a validação permanecia em ≈0,11 — diferença superior a duas vezes, indicando sobreajuste crescente mesmo com o maior *dataset* do estudo. O Optuna selecionou a arquitetura mais profunda (`n_layers=8`) com o menor `ff_dropout` (0,003). Val $\mathrm{MSE}_{\mathrm{norm}} = 0{,}0873$, melhor valor entre todos os experimentos. **(b)** O melhor alinhamento entre predição e observação de todo o estudo. Transições abruptas de temperatura — quedas noturnas de mais de 5 °C em menos de 3 horas — são capturadas com fidelidade superior à dos modelos menores, evidência de que 75 anos de variabilidade climática fornecem representações adequadas para esses eventos raros. A melhora em relação ao experimento de 50 anos é marginal (−1,3 % no RMSE), sugerindo que o ganho de dados adicionais começa a saturar e que o limite de informação útil da reanálise ERA5-Land para este ponto se aproxima. RMSE = 1,6530 °C | MAE = 1,2408 °C.

8 Inferência Pontual — 2 de Janeiro de 2026

O experimento de inferência pontual avalia os modelos num cenário de previsão do mundo real: cada modelo recebeu como contexto as 168 horas de ERA5-Land imediatamente anteriores à meia-noite de 2 de janeiro de 2026 e foi avaliado contra as temperaturas observadas nesse dia, num horizonte completo de 24 h.

8.1 Resultados Comparativos

Tabela 7: Métricas de inferência pontual para 2 de janeiro de 2026.

Modelo	**MSE (°C²)**	**RMSE (°C)**	**MAE (°C)**
5 anos	3,1143	1,7647	1,1833
10 anos	4,9961	2,2352	1,6582
50 anos	2,7684	1,6639	1,3429
75 anos	1,7550	**1,3248**	**1,1421**

O modelo de 75 anos obteve RMSE = 1,3248 °C para o dia 2/1/2026 — desempenho **40,7 %** melhor do que o modelo de 10 anos (RMSE = 2,2352 °C). Notavelmente, o modelo de 5 anos supera o de 10 anos neste caso pontual (1,7647 vs. 2,2352 °C), indicando que, para datas específicas recentes, a proximidade temporal do conjunto de treino pode ser mais relevante do que a profundidade histórica.

8.2 Resultados de Inferência por Experimento

As figuras a seguir são apresentadas em pares (temperatura prevista e erro horário, à esquerda e direita, respectivamente) para cada modelo, permitindo análise direta do comportamento ao longo do dia.

Modelo de 5 Anos

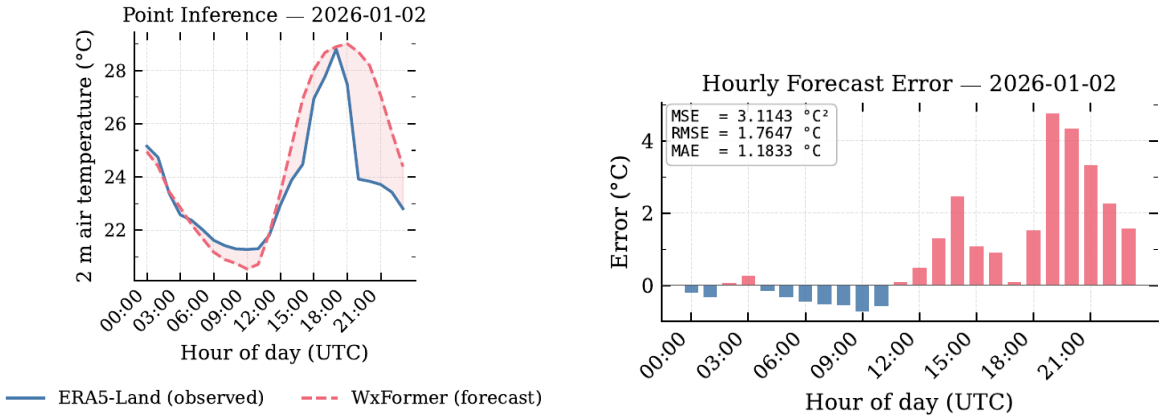

Figura 6: **WxFormer · 5 anos | Inferência 2/1/2026.** O modelo subestima sistematicamente as horas da madrugada (erros de −1 a −2 °C até 09:00 UTC) e superestima o período vespertino após a virada pós-pico (até +2,6 °C às 19:00 UTC). Apesar do menor conjunto de treino, este modelo se saiu melhor do que o de 10 anos neste dia específico, beneficiando-se de ter treinado com dados cronologicamente mais próximos da data-alvo.

Modelo de 10 Anos

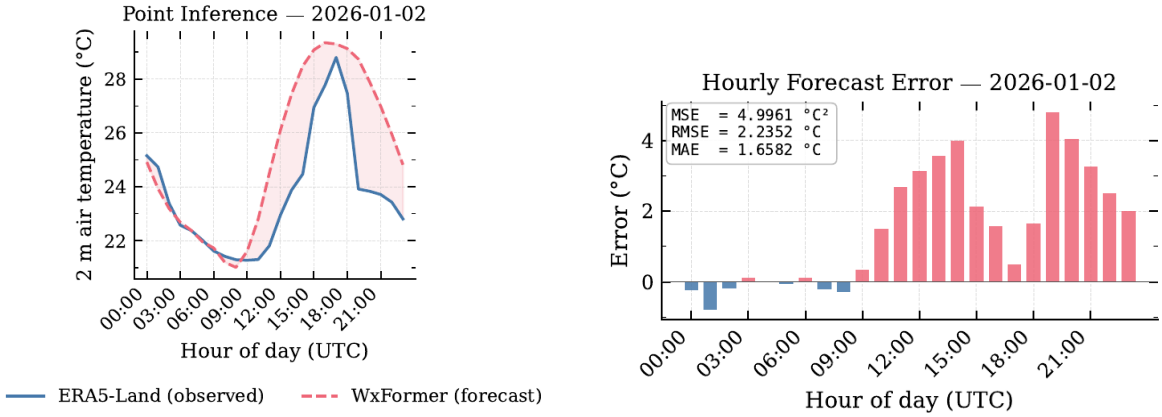

Figura 7: **WxFormer · 10 anos | Inferência 2/1/2026 — pior desempenho entre os quatro modelos.** O modelo superestima fortemente o pico diurno (erros de +3 a +4,8 °C entre 12:00 e 20:00 UTC), incapaz de antecipar o resfriamento abrupto da transição vespertina. Esse comportamento pode refletir que, para datas de verão em Campinas, os padrões de convecção pós-pico exigem uma densidade histórica maior do que 7 anos de treino para serem bem representados.

Modelo de 50 Anos

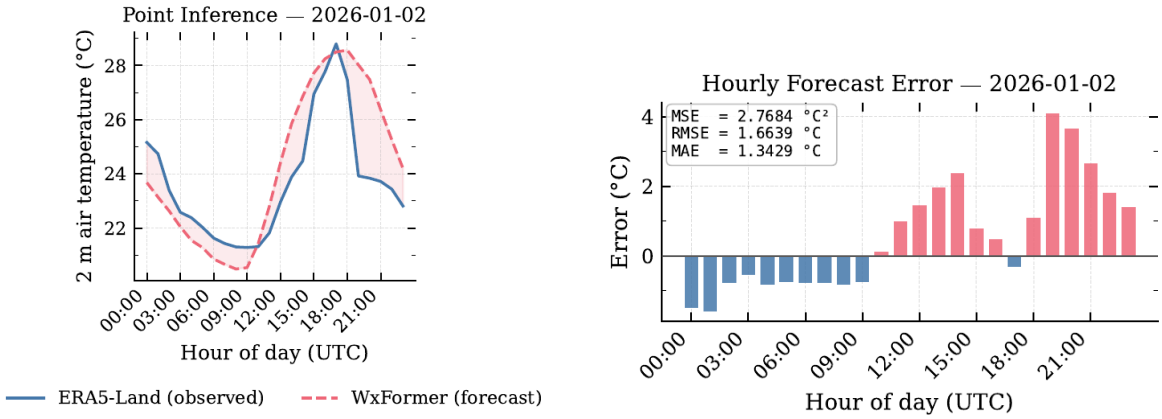

Figura 8: **WxFormer · 50 anos | Inferência 2/1/2026.** A trajetória diurna é bem reproduzida, com erros concentrados na madrugada (−0,7 a −1,6 °C) e na transição vespertina (+0,8 a +4,1 °C). A drástica melhora em relação ao modelo de 10 anos evidencia o impacto de um conjunto histórico amplo sobre a capacidade de previsão em situações específicas; o erro máximo cai de +4,8 °C para +4,1 °C, mas sua assinatura temporal permanece similar.

Modelo de 75 Anos — Melhor Desempenho

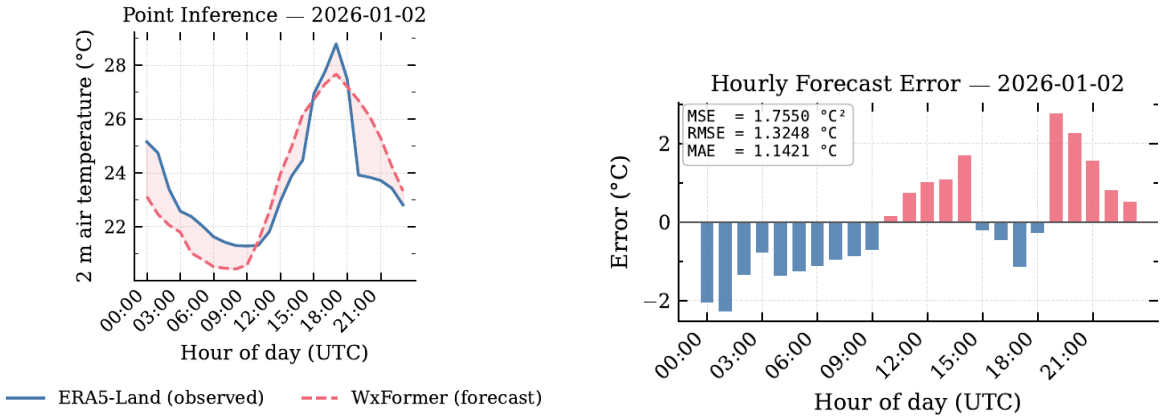

Figura 9: **WxFormer · 75 anos | Inferência 2/1/2026 — Melhor Desempenho.** O modelo reproduz a depressão noturna e o pico diurno com maior fidelidade do que os demais. O padrão de erro mantém a mesma assinatura temporal (subestimação na madrugada e superestimação pós-pico), mas com magnitude substancialmente menor: o erro máximo cai para +2,8 °C às 19:00 UTC, frente a +4,8 °C do modelo de 10 anos. Essa convergência sugere que o residual de erro não é eliminável com mais dados históricos, mas é uma limitação intrínseca da previsibilidade física da transição convectiva vespertina em clima tropical úmido.

9 Explicabilidade (Etapa 13)

9.1 Pesos de Atenção

Os pesos de atenção $W_{\text{attn}}(i, j)$ da última camada do *encoder* são extraídos via *forward hook*. A matriz $(P \times P)$ é visualizada como mapa de calor, onde cada célula (i, j) representa a atenção do *patch* i ao *patch* j.

> *"Atenção" não é necessariamente equivalente a "importância causal"* (Jain & Wallace, 2019) [26], mas fornece uma janela interpretativa útil sobre quais regiões temporais o modelo privilegia.

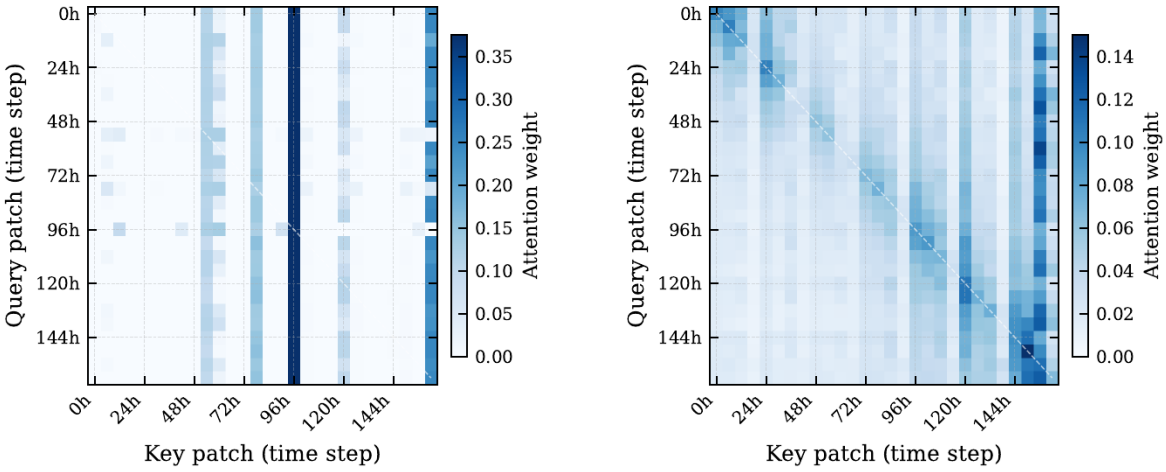

Figura 10: **Pesos de Atenção Médios $\bar{W}_{\text{attn}}(i, j)$ — 5 anos (esquerda) vs. 75 anos (direita).** Cada célula (i, j) representa a atenção do patch i (consulta) ao patch j (contexto); cada patch equivale a 6 h ($P = 28$ patches). *5 anos:* os pesos concentram-se em linhas verticais bem delimitadas, com maior intensidade ao redor dos patches correspondentes a ≈96 h (4 dias atrás), seguido de ≈168 h (início da janela), ≈72 h, ≈48 h e ≈120 h, com pesos residuais dispersos próximos a 0 h. Esse padrão revela que o modelo, independentemente de qual patch está consultando, privilegia sistematicamente as mesmas posições absolutas do contexto — comportamento distinto da localidade temporal e sugestivo de memorização de ritmos periódicos específicos. *75 anos:* a distribuição é mais difusa, com energia distribuída em bandas mais amplas, sugerindo que o modelo mais profundo aprendeu a combinar múltiplas escalas temporais de forma mais flexível.

9.2 Saliência Gradient × Input

O método *Gradient* × *Input* [27] calcula, para cada *feature* em cada passo de tempo, a saliência:

$$\text{saliência}(t, f) = \left| \frac{\partial \hat{y}_0}{\partial X_{t,f}} \right| \times |X_{t,f}|.$$

Esse método considera a magnitude do *input*, tornando a importância relativa mais estável e interpretável do que o gradiente puro.

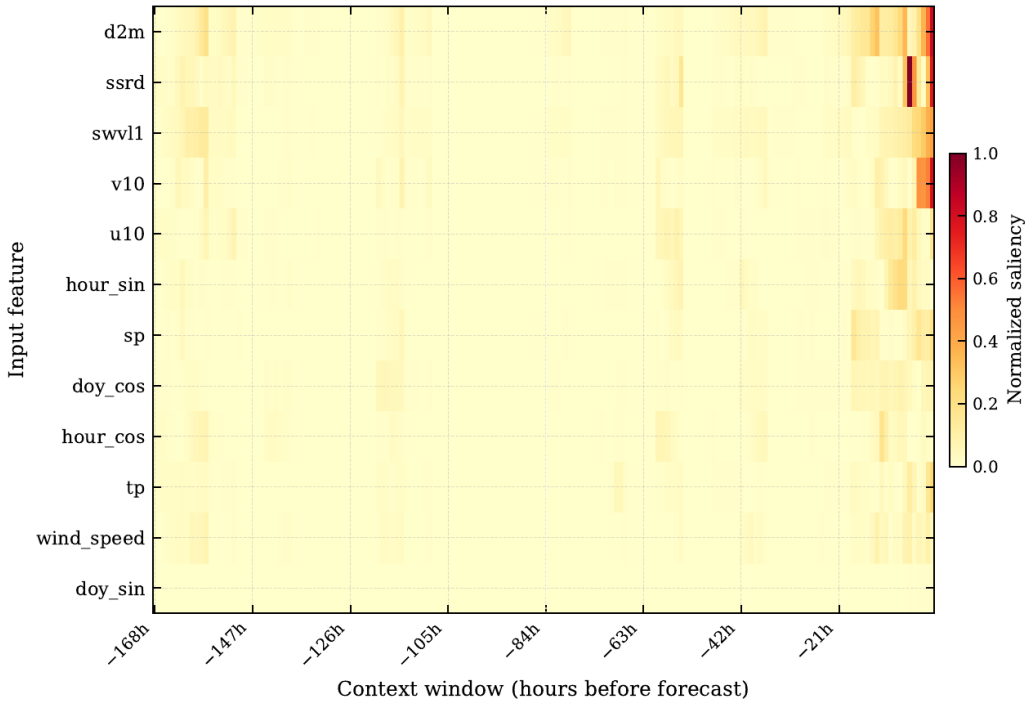

Figura 11: **WxFormer · 5 anos | Saliência Gradient × Input, previsão t+1 h.** Eixo vertical: 12 *features* de entrada; eixo horizontal: 168 passos da janela de contexto (tempo zero à direita). A saliência concentra-se fortemente nas 24–48 h imediatamente anteriores ao horizonte, com `d2m` (ponto de orvalho) como preditor mais dominante, seguido de `ssrd` (radiação solar). Esse padrão é fisicamente coerente: o ponto de orvalho, como medida direta do conteúdo de vapor d'água atmosférico, está intimamente ligado à temperatura de bulbo úmido e determina a amplitude do ciclo diurno e o resfriamento noturno por radiação — tornando-o o sinal mais informativo para a previsão imediata. A radiação solar das últimas horas complementa esse sinal como indicador do aquecimento diurno recente. As *features* de vento (`u10`, `v10`) apresentam saliência baixa, indicando que o modelo não explorou adequadamente a advecção horizontal — limitação esperada numa série temporal de ponto único.

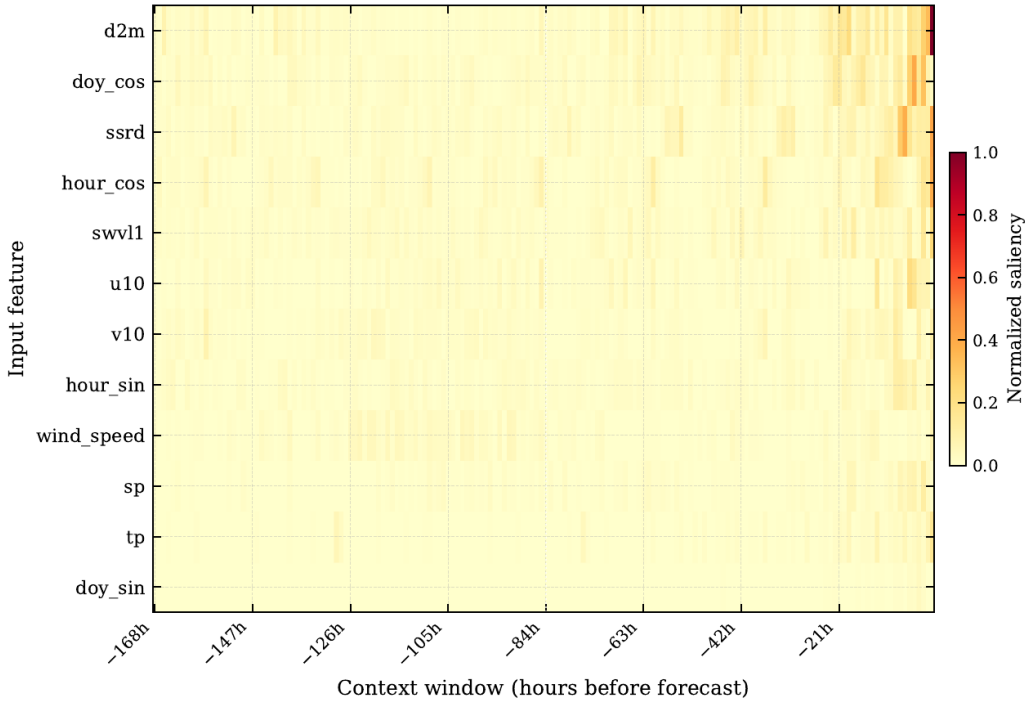

Figura 12: **WxFormer · 75 anos | Saliência Gradient × Input, previsão t+1 h.** Em relação ao modelo de 5 anos, a saliência distribui-se de forma mais homogênea ao longo da janela de contexto: o modelo de 8 camadas aprendeu a integrar informação de períodos mais distantes (48–168 h atrás), capturando dependências de múltiplos ciclos diurnos. A contribuição relativa de `swvl1` (umidade do solo) aumenta, condizente com o papel da evapotranspiração na regulação térmica superficial em escalas de dias a semanas — padrão que apenas emerge quando o modelo é treinado sobre décadas de variabilidade climática. A dominância de `d2m` permanece, confirmando a estabilidade desse preditor físico independentemente do tamanho do *dataset*.

10 Conclusão

Este trabalho apresentou o **WxFormer**, uma arquitetura Transformer customizada para a previsão horária da temperatura do ar a 2 metros em Campinas (SP), avaliada sob quatro regimes de dados históricos: 5, 10, 50 e 75 anos de reanálise ERA5-Land. O conjunto de experimentos permitiu estudar sistematicamente a relação entre volume de dados históricos e qualidade preditiva, com resultados que oferecem implicações práticas e teóricas para o desenvolvimento de modelos meteorológicos baseados em aprendizado profundo.

Resultados Principais

Volume histórico e desempenho. A hipótese central do estudo — de que mais dados históricos melhoram o desempenho — foi confirmada de forma consistente, porém com retornos decrescentes. A maior melhora proporcional ocorreu entre 10 e 50 anos

(−8,8 % no RMSE do teste), ao passo que a transição de 50 para 75 anos trouxe apenas −1,3 %. Isso sugere a existência de um patamar de saturação: a partir de certo volume histórico, a variabilidade climática adicional não é mais informativamente nova para o modelo, e o ganho marginal diminui.

Arquitetura e escala. O Optuna revelou uma tendência sistemática na seleção de hiperparâmetros: à medida que o dataset cresce, arquiteturas mais profundas (`n_layers`: 2 → 8) e mais estreitas (`d_model`: 512 → 128) passam a ser preferidas, com *dropout* progressivamente menor. Essa observação está alinhada com a literatura sobre *double descent* e regularização implícita por dados [20, 7]: num regime de muitos dados, a capacidade de memorização se torna menos relevante do que a profundidade de representação.

Padrão de erro e interpretabilidade. Todos os modelos compartilham a mesma assinatura temporal de erro: subestimação na madrugada e superestimação na transição pós-pico vespertino (19:00–21:00 UTC). A análise de saliência (*Gradient* × *Input*) revelou que `ssrd` e `d2m` são consistentemente os preditores mais influentes, enquanto os componentes de vento contribuem de forma secundária. O modelo de 75 anos demonstra uma utilização mais distribuída do contexto histórico (48–168 h), indicando que a profundidade temporal da atenção cresce com a disponibilidade de dados.

Transferência para inferência real. No experimento de inferência pontual (2/1/2026), o modelo de 75 anos atingiu RMSE de 1,3248 °C e MAE de 1,1421 °C, com desempenho 40,7 % melhor do que o modelo de 10 anos. O resultado excepcional do modelo de 5 anos nesse dia específico (superando o de 10 anos) evidencia que, em configurações pontuais, a proximidade temporal do conjunto de treino pode compensar parcialmente a menor diversidade histórica.

Limitações

O WxFormer opera sobre uma série temporal de ponto único; a ausência de informação espacial adjacente (campos de vento e umidade em pontos vizinhos) limita a capacidade de capturar advecção horizontal e sistemas de mesoescala. Além disso, o modelo foi avaliado exclusivamente sobre ERA5-Land — uma reanálise com suas próprias incertezas — e não sobre observações diretas de estações meteorológicas, o que constitui um passo necessário para validação operacional.

Extensões Futuras

As extensões naturais deste trabalho incluem: (i) incorporação de variáveis de campos espaciais vizinhos como *features* adicionais; (ii) avaliação do modelo em múltiplos

pontos simultaneamente, explorando a arquitetura Transformer como codificador espaço-temporal; (iii) comparação direta com modelos autorregressivos clássicos (SARIMA, Prophet) e *baselines* de aprendizado profundo (LSTM, TCN); e (iv) treinamento sobre dados observacionais de estações do INMET (Instituto Nacional de Meteorologia) para validação em cenário operacional real.

Síntese: o WxFormer demonstrou que arquiteturas Transformer com *Temporal Patch Embedding* e *Temporal Decay Bias* são capazes de aprender padrões meteorológicos relevantes diretamente de reanálises horárias, atingindo RMSE de 1,65 °C no conjunto de teste e 1,32 °C na inferência pontual com 75 anos de histórico. A relação entre volume de dados e desempenho segue uma lei de retornos decrescentes, com o regime de 50–75 anos representando o ponto de equilíbrio entre custo computacional e ganho preditivo para este problema.

Referências

[1] EUROPEAN CENTRE FOR MEDIUM-RANGE WEATHER FORECASTS (ECMWF). *ERA5-Land hourly data from 1950 to present*. Climate Data Store (CDS), 2019. DOI: 10.24381/cds.e2161bac.

[2] HOYER, S.; HAMMAN, J. Xarray: N-D labeled arrays and datasets in Python. *Journal of Open Research Software*, v. 5, n. 1, p. 10, 2017. DOI: 10.5334/jors.148.

[3] RASP, S. et al. WeatherBench: A benchmark data set for data-driven weather forecasting. *Journal of Advances in Modeling Earth Systems*, v. 12, n. 11, e2020MS002203, 2020. DOI: 10.1029/2020MS002203.

[4] CLEVELAND, W. S.; DEVLIN, S. J. Locally weighted regression: An approach to regression analysis by local fitting. *Journal of the American Statistical Association*, v. 83, n. 403, p. 596–610, 1988.

[5] PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011.

[6] GERON, A. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 3. ed. Sebastopol: O'Reilly Media, 2022.

[7] NIE, Y. et al. A time series is worth 64 words: Long-term forecasting with transformers. In: *International Conference on Learning Representations (ICLR)*, 2023. arXiv:2211.14730.

[8] DOSOVITSKIY, A. et al. An image is worth 16×16 words: Transformers for image recognition at scale. In: *ICLR*, 2021. arXiv:2010.11929.

[9] XIONG, R. et al. On layer normalization in the transformer architecture. In: *ICML*, 2020. arXiv:2002.04745.

[10] VASWANI, A. et al. Attention is all you need. In: *NeurIPS*, v. 30, 2017. arXiv:1706.03762.

[11] PRESS, O. et al. Train short, test long: Attention with linear biases enables input length extrapolation. In: *ICLR*, 2022. arXiv:2108.12409.

[12] ZEHUI, L. et al. EfficientBERT: Progressively searching multilayer perceptron on BERT compression. In: *Findings of EMNLP*, 2021.

[13] PRECHELT, L. Early stopping — but when? In: *Neural Networks: Tricks of the Trade*. 2. ed. Berlin: Springer, 2012. p. 53–67.

[14] PASCANU, R.; MIKOLOV, T.; BENGIO, Y. On the difficulty of training recurrent neural networks. In: *ICML*, 2013. arXiv:1211.5063.

[15] LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: *ICLR*, 2019. arXiv:1711.05101.

[16] HENDRYCKS, D.; GIMPEL, K. Gaussian error linear units (GELUs). arXiv preprint, 2016. arXiv:1606.08415.

[17] BERGSTRA, J.; BENGIO, Y. Random search for hyper-parameter optimization. *Journal of Machine Learning Research*, v. 13, p. 281–305, 2012.

[18] BERGSTRA, J. et al. Algorithms for hyper-parameter optimization. In: *NeurIPS*, v. 24, 2011.

[19] LI, L. et al. Hyperband: A novel bandit-based approach to hyperparameter optimization. *Journal of Machine Learning Research*, v. 18, n. 1, p. 6765–6816, 2018.

[20] DEVLIN, J. et al. BERT: Pre-training of deep bidirectional transformers for language understanding. In: *NAACL*, 2019. arXiv:1810.04805.

[21] LOSHCHILOV, I.; HUTTER, F. SGDR: Stochastic gradient descent with warm restarts. In: *ICLR*, 2017. arXiv:1608.03983.

[22] GOYAL, P. et al. Accurate, large minibatch SGD: Training ImageNet in 1 hour. arXiv preprint, 2017. arXiv:1706.02677.

[23] LIU, X. et al. On the variance of the adaptive learning rate and beyond. In: *ICLR*, 2020. arXiv:1908.03265.

[24] CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? *Geoscientific Model Development*, v. 7, n. 3, p. 1247–1250, 2014.

[25] HYNDMAN, R. J.; KOEHLER, A. B. Another look at measures of forecast accuracy. *International Journal of Forecasting*, v. 22, n. 4, p. 679–688, 2006.

[26] JAIN, S.; WALLACE, B. C. Attention is not explanation. In: *NAACL*, 2019. arXiv:1902.10186.

[27] SHRIKUMAR, A. et al. Learning important features through propagating activation differences. In: *ICML*, 2017.

[28] AKIBA, T. et al. Optuna: A next-generation hyperparameter optimization framework. In: *ACM SIGKDD*, 2019.

[29] ABNAR, S.; ZUIDEMA, W. Quantifying attention flow in transformers. In: *ACL*, 2020. arXiv:2005.00928.

[30] SIMONYAN, K. et al. Deep inside convolutional networks: Visualising image classification models and saliency maps. In: *ICLR Workshop*, 2014. arXiv:1312.6034.